

Entregable 3

Unsupervised Machine Learning

A continuación se explica todo lo necesario para esta actividad:

1. Formulario de Google: Son un total de 10 preguntas donde cada una vale 0,5 puntos (pueden sumar un total de 5 puntos). La mitad de las preguntas son teóricas sobre Series Temporales y la otra mitad son preguntas sobre el dataset de la competición de Kaggle (siguiente punto).

El formulario lo encontraréis en el siguiente enlace: <https://forms.gle/VBd9B6vFM56owcFv9>

Importante: Cuando acabéis el formulario le debéis dar al botón de "Enviar".

2. Competición de Kaggle: aquí lo fundamental es mejorar el modelo base que tenemos implementado (notebook Kaggle Benchmark.ipynb).


<https://www.kaggle.com/t/bd9c5ec414a94d098ff5bb8acfd2ff98>

En Kaggle nuestro objetivo es entrenar un modelo sobre Series Temporales Multivariante (tenemos un dataset de más de 400 ts) y cada una de las ts tienen 33 meses de histórico (empiezan en Enero-2013 y llegan hasta Septiembre-2015). Nosotros tenemos que predecir las ventas esperadas por cada uno de los unique_id para Octubre-2015.

Algunas consideraciones importante sobre Kaggle:

Con la competición de Kaggle buscamos varios objetivos:

1. Que tengáis un entorno para poder practicar vuestros conocimientos de pandas, feature engineering y modelización de Time Series.
2. Aprendan a cross-validar correctamente las Series Temporales.
3. Entiendan de primera mano la importancia de tener un benchmark cuando empiezan cualquier proyecto de Data Science.
4. Puedan experimentar el feature engineering y detectar posible data/target leakage en la construcción de vuestras variables (sobre todo mucho cuidado con medias móviles).



Algunas reglas sobre el funcionamiento de la competición de Kaggle:

1. En Kaggle existen 2 leaderboards: público y privado. El público se construye con el 30% (aprox.) de los datos y el privado son el 70% restante. Aquí me refiero a nuestras predicciones de Octubre-2015. Cuando hacemos un submit a la competición de Kaggle vemos el score que sale en público (RMSE sobre el 30%). Esto nos permite ver cómo evoluciona nuestro modelo.

OJO: una posición "alta" en el leaderboard público no siempre garantiza la misma posición en privado. Si tengo variables que "sobreajustan" al público, puedo llegar a tener un modelo muy malo para las Series Temporales que tengo en privado.

2. Pueden llegar a hacer hasta 5 submits al día. Si llegan a este máximo deben esperar al día siguiente para volver a subir un score.

3. Por defecto Kaggle va a seleccionar el submit que mejor score tiene en público (esto no es siempre lo que nos interesa, mirar punto 1). Para seleccionar el submit definitivo, deben ir al enlace de la competición → submissions → marcar el submit que más nos interesa. Dado que van a hacer muchos experimentos y pruebas, es fundamental que hagan apuntes sobre que se hace en cada submit para luego poder seleccionar el que más nos gusta.

4. No pueden ni deben compartir código entre vosotros por privado. Si quieren compartir código y/o ideas, deben utilizar la sección de Code o Discussions de la competición para que sea visible para todos.